

PCA

Principal Component  
Analysis

RECORDAR É VIVER...

①

PRODUTO INTERNO DE 2 VETORES  $\underline{v} = \begin{pmatrix} v_1 \\ \vdots \\ v_p \end{pmatrix} \in \underline{w} = \begin{pmatrix} w_1 \\ \vdots \\ w_p \end{pmatrix}$


$$\oplus \langle \underline{v}, \underline{w} \rangle = \sum_{i=1}^p w_i v_i = (v_1 \dots v_p) \cdot \begin{pmatrix} w_1 \\ \vdots \\ w_p \end{pmatrix} = \underline{v}^t \cdot \underline{w}$$

$$\oplus \underline{v}^t \cdot \underline{w} = \underline{w}^t \cdot \underline{v}$$

$\oplus$  Como  $\underline{v}^t \cdot \underline{w}$  é um NÚMERO REAL então

$$\cancel{\underline{v}^t \cdot \underline{w}} (\underline{v}^t \cdot \underline{w})^2 = (\underline{v}^t \cdot \underline{w}) (\underline{v}^t \cdot \underline{w}) = (\underline{v}^t \cdot \underline{w}) (\underline{w}^t \cdot \underline{v}) = \underline{v}^t \cdot (\underline{w} \underline{w}^t) \cdot \underline{v}$$

$\oplus$  PROJEÇÃO ORTOGONAL ( $\perp$ ) DE  $\underline{v}$  EM  $\underline{w}$ :



$$? = (\underline{v}^t \underline{w}) \cdot \frac{\underline{w}}{\|\underline{w}\|^2}$$

$$\text{SE } \|\underline{w}\|=1 \text{ ENTÃO PROJEÇÃO} = (\underline{v}^t \underline{w}) \underline{w}$$

## COVARIÂNCIA

(2)

$$\text{Cov}(Y_i, Y_j) = \underbrace{\mathbb{E}((Y_i - \mu_i) \cdot (Y_j - \mu_j))}_{\text{Covariância}} = \rho_{ij} \sigma_i \sigma_j$$

## MATRIZ DE COVARIÂNCIA

$$\sum_{p \times p} = V(\underline{Y}) = \begin{bmatrix} V(Y_1) & \text{Cov}(Y_1, Y_2) & \text{Cov}(Y_1, Y_3) & \dots & \text{Cov}(Y_1, Y_p) \\ \text{Cov}(Y_2, Y_1) & V(Y_2) & \text{Cov}(Y_2, Y_3) & \dots & \text{Cov}(Y_2, Y_p) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(Y_p, Y_1) & \text{Cov}(Y_p, Y_2) & \text{Cov}(Y_p, Y_3) & \dots & V(Y_p) \end{bmatrix}$$

Verifique que vale a igualdade abaixo (exercício):

$$\Sigma = \mathbb{E}[(\underline{Y} - \underline{\mu})(\underline{Y} - \underline{\mu})^T] = \mathbb{E}\left[\begin{pmatrix} Y_1 - \mu_1 \\ \vdots \\ Y_p - \mu_p \end{pmatrix} (Y_1 - \mu_1, \dots, Y_p - \mu_p)\right] = \mathbb{E}\begin{bmatrix} (Y_1 - \mu_1)^2 & (Y_1 - \mu_1)(Y_2 - \mu_2) & \dots \\ (Y_2 - \mu_2)(Y_1 - \mu_1) & (Y_2 - \mu_2)^2 & \dots \\ \vdots & \vdots & \ddots \\ (Y_p - \mu_p)(Y_1 - \mu_1) & (Y_p - \mu_p)(Y_2 - \mu_2) & \dots \end{bmatrix}$$

(3)

$$\textcircled{*} \quad \underset{\sim}{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_p \end{pmatrix} \sim N_p \left( \underset{p \times 1}{\underset{\sim}{\mu}}, \sum_{p \times p} \right)$$

$\textcircled{*}$  CONTORNOS DE DENSIDADE CONSTANTE SÃO ELÍPSÓIDES EM  $\underset{\sim}{y}$  DEFINIDOS POR

$$(\underset{\sim}{y} - \underset{\sim}{\mu})' \sum^{-1} (\underset{\sim}{y} - \underset{\sim}{\mu}) = c > 0$$

$\textcircled{*}$  ESTES ELÍPSÓIDES SÃO CENTRADOS EM  $\underset{\sim}{\mu}$  E TÊM EIXOS  $\pm c \sqrt{\lambda_i} \underset{\sim}{v}_i$  ONDE  $\sum \underset{\sim}{v}_i = \lambda_i \underset{\sim}{v}_i$  PARA  $i=1, 2, \dots, p$

$\textcircled{*}$  ORDENAMOS OS AUTOVALORES DE FORMA QUE

$$\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_p > 0$$


$\textcircled{*}$  CHAMAMOS  $\underset{\sim}{v}_1$  DE PRIMEIRO AUTOVETOR OU 1º COMPONENTE PRINCIPAL

$\underset{\sim}{v}_2$  " SEGUNDO " " 2º " "  
 etc.

AMOSTRA DE

$$Y \sim N_3 \left( \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix}, \Sigma \right)$$

(4)



⊕ Suponha que o menor autovalor  $\lambda_p$  seja  $\approx 0$  (5)

⊕ Isto implica que o elipsóide e a nuvem de pontos serão achatados.

⊕ O que podemos fazer com isto?

⊕ Isto implica que o vetor  $\underline{Y}$  vive aproximadamente num espaço de dimensão MENOR que sua dimensão  $p$

⊕ Podemos reduzir o n.º de dimensões do vetor  $\underline{Y}$

⊕ Esta redução está associada com os autovalores de  $\Sigma$



⊕ Não tem nenhuma relação com o vetor esperado  $\underline{\mu}$

⊕ É mais fácil trabalhar com o vetor  $\underline{Y}$  centrado em 0

pois vamos trabalhar com vetores e matrizes.

⊕ Defina  $\underline{X} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix} = \underline{Y} - \underline{\mu} = \begin{pmatrix} y_1 \\ \vdots \\ y_p \end{pmatrix} - \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_p \end{pmatrix} = \begin{pmatrix} y_1 - \mu_1 \\ \vdots \\ y_p - \mu_p \end{pmatrix}$

⊕ Veja que, se  $Y \sim N_p(\mu, \Sigma)$  então  $X = Y - \mu \sim N_p(0, \Sigma)$  ⑥  
 $\Rightarrow$  MESMA  $\Sigma$



⊕ SOMENTE DESLOCAMOS RIGIDAMENTE O ELIPSÓIDE  
 DE FORMA QUE FIQUE CENTRADO NA ORIGEM.

⊕



\* Pelo Teorema espectral, podemos diagonalizar  $\Sigma$  usando seus autovetores: ⑦

$$\Sigma = P \Lambda P^t$$

onde  $P_{p \times p} = [\underline{v}_1 | \underline{v}_2 | \dots | \underline{v}_p]$  é a matriz cujas colunas são os autovetores de  $\Sigma$

$\Lambda = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{pmatrix}$  é a matriz diagonal com os autovalores de  $\Sigma$

e os autovetores são ortogonais de comprimento 1 de forma que

$$\underline{v}_i^t \cdot \underline{v}_j = \delta_{ij} = \begin{cases} 1, \text{ se } i=j \\ 0, \text{ caso contrário} \end{cases}$$

$$(\text{Ou seja, } P^t \cdot P = I)$$



⊕ COMO OS  $\underline{v}$  AUTOVETORES SÃO ORTOGONAIS, eles formam ⑧  
uma base do espaço  $\mathbb{R}^p$

⊕ O vetor aleatório  $\underline{X} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix}$  pode ser escrito como

$$\underline{X} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} = c_1 \underline{v}_1 + c_2 \underline{v}_2 + \dots + c_p \underline{v}_p$$

⊕ Os valores de  $c_i$  são obtidos facilmente usando que os  $\underline{v}_i$ 's são  $\perp$ 's e têm comprimento 1. Por exemplo, para  $c_1$ :

$$\begin{aligned} \underline{v}_1^t \cdot \underline{X} &= \underline{v}_1^t (c_1 \underline{v}_1 + c_2 \underline{v}_2 + \dots + c_p \underline{v}_p) \\ &= c_1 \underbrace{(\underline{v}_1^t \cdot \underline{v}_1)}_{\|\underline{v}_1\|^2 = 1^2 = 1} + c_2 \underbrace{(\underline{v}_1^t \cdot \underline{v}_2)}_{0 \text{ pois } \perp} + \dots + c_p \underbrace{(\underline{v}_1^t \cdot \underline{v}_p)}_{0 \text{ pois } \perp} = c_1 \end{aligned}$$

$$\text{Isto é, } c_1 = \underline{v}_1^t \cdot \underline{X}$$

(9)

Do mesmo modo, para obter  $c_2$

$$\underline{v}_2' \cdot \underline{X} = \underline{v}_2' (c_1 \underline{v}_1 + c_2 \underline{v}_2 + \dots + c_p \underline{v}_p)$$

$$= c_1 \underbrace{\underline{v}_2' \underline{v}_1}_0 + c_2 \underbrace{\underline{v}_2' \underline{v}_2}_1 + \dots + c_p \underbrace{\underline{v}_2' \underline{v}_p}_0 = c_2$$

~~Assim~~ Assim, a representação de  $\underline{X} = \underline{Y} - \underline{\mu}$  na ~~base~~ base  $\underline{v}_1, \underline{v}_2, \dots, \underline{v}_p$  de autovetores de  $\Sigma$  é dada por

$$\underline{X} = \underbrace{(\underline{v}_1' \cdot \underline{X})}_{\in \mathbb{R}} \underline{v}_1 + \underbrace{(\underline{v}_2' \cdot \underline{X})}_{\in \mathbb{R}} \underline{v}_2 + \dots + \underbrace{(\underline{v}_p' \cdot \underline{X})}_{\in \mathbb{R}} \underline{v}_p$$

⊕ Suponha que os primeiros  $K$  autovalores sejam muito maiores que os últimos  $p-K$

⊕ Vamos supor que 
$$\begin{cases} \lambda_{K+1} \approx 0 \\ \lambda_{K+2} \approx 0 \\ \vdots \\ \lambda_p \approx 0 \end{cases}$$

⊕ Vamos usar uma aproximação  $X^*$  para  $X$  dada apenas pelos  $K$  primeiros coordenados:

$$\underset{\sim}{X} = c_1 \begin{pmatrix} \underset{\sim}{v}_1 \\ \underset{\sim}{v}_1 \end{pmatrix} + c_2 \begin{pmatrix} \underset{\sim}{v}_2 \\ \underset{\sim}{v}_2 \end{pmatrix} + \dots + c_K \begin{pmatrix} \underset{\sim}{v}_K \\ \underset{\sim}{v}_K \end{pmatrix} + c_{K+1} \begin{pmatrix} \underset{\sim}{v}_{K+1} \\ \underset{\sim}{v}_{K+1} \end{pmatrix} + \dots + c_p \begin{pmatrix} \underset{\sim}{v}_p \\ \underset{\sim}{v}_p \end{pmatrix}$$

$$\approx c_1 \underset{\sim}{v}_1 + c_2 \underset{\sim}{v}_2 + \dots + c_K \underset{\sim}{v}_K + \cancel{c_{K+1} \begin{pmatrix} \underset{\sim}{v}_{K+1} \\ \underset{\sim}{v}_{K+1} \end{pmatrix}} + \dots + \cancel{c_p \begin{pmatrix} \underset{\sim}{v}_p \\ \underset{\sim}{v}_p \end{pmatrix}}$$

$$= X^*$$

LEMBRE-SE:  $c_i = \underset{\sim}{v}_i^T \cdot \underset{\sim}{X}$

⊕ Vamos mostrar agora que  $\underset{\sim}{X} \approx \underset{\sim}{X}^*$  !!

⊕ AMBOS SÃO vetores do  $\mathbb{R}^p$ .

$$\underset{\sim}{X} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \quad \underset{\sim}{X}^* = c_1 \underbrace{\begin{pmatrix} v_1 \\ \vdots \\ v_k \end{pmatrix}}_{\in \mathbb{R}^p} + \dots + c_k \underbrace{\begin{pmatrix} v_k \\ \vdots \\ v_k \end{pmatrix}}_{\in \mathbb{R}^p}$$

⊕ Qual a vantagem então ??

⊕ Suponha que  $p = 20000$  e  $k = 10$

⊕ O vetor  $\underset{\sim}{X}$  precisa de 20000 coordenadas.

⊕ O vetor  $\underset{\sim}{X}^*$  precise de : 10  $\mu s$  ( $c_1, c_2, \dots, c_k$ )  
e os  $k$  vetores  $\underset{\sim}{v}_1, \dots, \underset{\sim}{v}_k$

⊕ Para várias instâncias  $\underset{\sim}{X}_1, \underset{\sim}{X}_2, \dots, \underset{\sim}{X}_m$  os  $k$  vetores  $\underset{\sim}{v}_1, \dots, \underset{\sim}{v}_k$  são os mesmos. Para diferenciá-los só precisamos de  $c_{11}, \dots, c_{km}$  de cada um deles.

⊕ Isto ficará claro na aplicação de reconhecimento de faces (a seguir)

⊕ Agora vamos provar que  $\underline{X} \approx \underline{X}^*$

⊕  $\underline{X}$  e  $\underline{X}^*$  são vetores aleatórios

⊕ Para mostrar que, em geral, temos  $\underline{X} \approx \underline{X}^*$ , vamos tomar a distância (ao quadrado) entre eles

$$\underbrace{\|\underline{X} - \underline{X}^*\|^2}_{>0} \text{ e mostrar que } E(\|\underline{X} - \underline{X}^*\|^2) \approx 0$$

~~Prova:  $\|\underline{X} - \underline{X}^*\|^2 = \|c_1 \underline{v}_1 + \dots + c_k \underline{v}_k + c_{k+1} \underline{v}_{k+1} + \dots + c_p \underline{v}_p - (c_1 \underline{v}_1 + \dots + c_p \underline{v}_p)\|^2$~~

⊕ Prova:

$$\|\underline{X} - \underline{X}^*\|^2 = \|c_1 \underline{v}_1 + \dots + c_k \underline{v}_k + \underbrace{c_{k+1} \underline{v}_{k+1} + \dots + c_p \underline{v}_p}_{\text{SÓ VAI SOBRAIR ISTO}} - (c_1 \underline{v}_1 + \dots + c_p \underline{v}_p)\|^2$$

SÓ VAI SOBRAIR ISTO

Então

(13)

$$\|\underline{\underline{x}} - \underline{\underline{x}}^*\|^2 = \|C_{k+1} \underline{\underline{v}}_{k+1} + \dots + C_p \underline{\underline{v}}_p\|^2$$

$$= C_{k+1}^2 \|\underline{\underline{v}}_{k+1}\|^2 + \dots + C_p^2 \|\underline{\underline{v}}_p\|^2 \text{ pois os } \underline{\underline{v}}_i \text{'s são } \perp \text{'s}$$

$$= C_{k+1}^2 + \dots + C_p^2 \text{ pois os } \|\underline{\underline{v}}_i\| = 1$$

$$= \left( \underline{\underline{v}}_{k+1}' \underline{\underline{x}} \right)^2 + \dots + \left( \underline{\underline{v}}_p' \underline{\underline{x}} \right)^2$$

$$= \left( \underline{\underline{v}}_{k+1}' \underline{\underline{x}} \right) \left( \underline{\underline{x}}^t \underline{\underline{v}}_{k+1} \right) + \dots + \left( \underline{\underline{v}}_p' \underline{\underline{x}} \right) \left( \underline{\underline{x}}^t \underline{\underline{v}}_p \right)$$

$$= \underline{\underline{v}}_{k+1}' \left( \underline{\underline{x}} \underline{\underline{x}}^t \right) \underline{\underline{v}}_{k+1} + \dots + \underline{\underline{v}}_p' \left( \underline{\underline{x}} \underline{\underline{x}}^t \right) \underline{\underline{v}}_p$$

Note que

$$\underline{\underline{x}} \underline{\underline{x}}^t = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} (x_1 \dots x_p) = \begin{pmatrix} x_1^2 & x_1 x_2 & \dots & x_1 x_p \\ x_2 x_1 & x_2^2 & \dots & x_2 x_p \\ \vdots & \vdots & \ddots & \vdots \\ x_p x_1 & x_p x_2 & \dots & x_p^2 \end{pmatrix}, \text{ uma matriz } p \times p$$

Encontramos que

$$\|\tilde{X} - \tilde{X}^*\|^2 = \tilde{v}_{k+1}' \tilde{X} \tilde{X}' \tilde{v}_{k+1} + \dots + \tilde{v}_p' \tilde{X} \tilde{X}' \tilde{v}_p$$

Assim,

$$\begin{aligned} E(\|\tilde{X} - \tilde{X}^*\|^2) &= E\left(\tilde{v}_{k+1}' \tilde{X} \tilde{X}' \tilde{v}_{k+1} + \dots + \tilde{v}_p' \tilde{X} \tilde{X}' \tilde{v}_p\right) \\ &= \tilde{v}_{k+1}' \underbrace{E(\tilde{X} \tilde{X}')}_{=\sum} \tilde{v}_{k+1} + \dots + \tilde{v}_p' \underbrace{E(\tilde{X} \tilde{X}')}_{=\sum} \tilde{v}_p \end{aligned}$$

$$= \tilde{v}_{k+1}' \underbrace{\sum \tilde{v}_{k+1}}_{\lambda_{k+1} \tilde{v}_{k+1}} + \dots + \tilde{v}_p' \underbrace{\sum \tilde{v}_p}_{\lambda_p \tilde{v}_p}$$

$$= \cancel{\lambda_{k+1}} \tilde{v}_{k+1}' \tilde{v}_{k+1} + \dots + \lambda_p \tilde{v}_p' \tilde{v}_p$$

$$= \lambda_{k+1} \|\tilde{v}_{k+1}\|^2 + \dots + \lambda_p \|\tilde{v}_p\|^2 = \lambda_{k+1} + \dots + \lambda_p \approx 0$$



Portanto, encontramos

$$E\left(\|\tilde{X} - \tilde{X}^*\|^2\right) \approx 0$$

$\|\tilde{X} - \tilde{X}^*\|^2$  é uma v.a. positiva cujo valor esperado é aproximadamente 0

Assim, ~~esperamos~~  $\|\tilde{X} - \tilde{X}^*\| = \sqrt{\|\tilde{X} - \tilde{X}^*\|^2} \approx 0$  TAMBÉM

MAS SE  $\|\tilde{X} - \tilde{X}^*\| \approx 0$  então  $\tilde{X} \approx \tilde{X}^*$

Conclusão Se os últimos autovalores forem próximos de zero podemos usar  $\tilde{X}^* \approx [\tilde{c}_1, \dots, \tilde{c}_k]$  que temos praticamente  $\tilde{X}$ .

representação  
na base  
 $\tilde{v}_1, \dots, \tilde{v}_k$

⊕ Isto é o melhor que podemos fazer? (16)

⊕ Existe outro conjunto ortonormal

$\tilde{w}_1, \tilde{w}_2, \dots, \tilde{w}_k$

tal que a projeção  $\perp \tilde{X}^{**}$  de  $\tilde{X}$  no

espaço gerado pelos  $\tilde{w}_i$ 's seja melhor


que a projeção  $\tilde{X}^*$  no espaço dos  $k$  1º  
autovetores  $\tilde{v}_1, \tilde{v}_2, \dots, \tilde{v}_k$ ?

⊕ Isto é, existe  $\tilde{w}_1, \tilde{w}_2, \dots, \tilde{w}_k$  tal que

$$E\left(\left\|\tilde{X} - \underset{\substack{\uparrow \\ \text{projec } \perp \text{ em } \tilde{w}_1, \tilde{w}_2, \dots, \tilde{w}_k}}{\tilde{X}^{**}}\right\|^2\right) < E\left(\left\|\tilde{X} - \underset{\substack{\uparrow \\ \text{projec } \perp \text{ em } \tilde{v}_1, \dots, \tilde{v}_k \text{ autovetores de } \Sigma}}{\tilde{X}^*}\right\|^2\right)?$$


- Como você podia antecipar pelo estilo retórico (17) da pergunta, a resposta é NÃO.
- O subespaço de dimensão  $K$  que minimiza o valor esperado do resíduo  $E(\|\tilde{X} - \tilde{X}^*\|^2)$  é o subespaço formado pelos  $1^{\circ}$  a  $K$  autovetores de  $\Sigma = \text{Var}(\tilde{X})$ .
- NENHUM OUTRO PODE REPRESENTAR  $\tilde{X}$  TÃO BEM (EM  $K$  dimensões) quanto os  $K$   $1^{\circ}$  autovetores de  $\Sigma$ .
- VAMOS PROVAR ISTO PARA  $K=1$ . MAS ANTES, UMAS FIGURAS...

PROCURAMOS UMA LINHA PASSANDO PELA ORIGEM (SUBESPAÇO DE DIMENSÃO  $K=1$ ) TAL QUE A DISTÂNCIA ALEATÓRIA  $\|\underline{x} - \underline{x}^*\|^2$  ENTRE  $\underline{x}$  E A SUA PROJEÇÃO  $\perp \underline{x}^*$  TENHA O VALOR ESPERADO MÍNIMO.



linha =  $\{c \underline{v} \text{ onde } c \in \mathbb{R}\}$   
= MÚLTIPLOS DO VETOR  $\underline{v}$

Escolhendo diferentes  $\underline{v}$ 's temos diferentes sub-espaços de  $\dim = 1$ .




$$\underset{\sim}{X} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \text{ vive em } \mathbb{R}^3 \quad (19)$$

$\underset{\sim}{X}$  é aleatório

$$E(\underset{\sim}{X}) = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

⇒ SE AMOSTRAMOS  $\underset{\sim}{X}$  VÁRIAS VEZES  
VEREMOS UMA NUVEM DE PONTOS CENTRADA  
NA ORIGEM NA FORMA DE UM ELIPSÓIDE




Fixe um  $\underline{v} \in \mathbb{R}^3$  qualquer e considere o vetor (20)  
 $\underline{x} \in \mathbb{R}^3$

$\underline{v} \in \mathbb{R}^3$  é com

$$\underline{\underline{\|\underline{v}\| = 1}}$$


$$\|\underline{v}\| = 1$$



PROJETA  $\underline{x}$  ORTOGONALMENTE EM  $\underline{v}$

(21)

$$\|\underline{\underline{v}}\| = 1$$



PROJEÇÃO DO  $\underline{\underline{X}}$  EM  $\underline{\underline{v}}$  (onde  $\|\underline{\underline{v}}\| = 1$ )

$$\text{é o vetor } \underline{\underline{X}}^* = c \cdot \underline{\underline{v}} = \underbrace{(\underline{\underline{v}}' \cdot \underline{\underline{X}})}_{\substack{\text{MÚLTIPLO} \\ \text{DE } \underline{\underline{v}}}} \cdot \underline{\underline{v}}$$



Queremos encontrar  $\underline{v} \in \mathbb{R}^p$  com  $\|\underline{v}\|=1$  tal (22)  
 que  $\underline{v}$  minimize  $E(\|\underline{X} - \underline{X}^*\|^2) = E(\|\underline{X} - (\underline{v}'\underline{X})\underline{v}\|^2)$   
 onde  $\underline{X}$  é vetor aleatório com  $E(\underline{X}) = \underline{0}$  e  $V(\underline{X}) = \Sigma$

$$\begin{aligned}
 \|\underline{X} - \underline{X}^*\|^2 &= \|\underline{X} - (\underline{v}'\underline{X})\underline{v}\|^2 = \langle \underline{X} - (\underline{v}'\underline{X})\underline{v}, \underline{X} - (\underline{v}'\underline{X})\underline{v} \rangle \\
 &= (\underline{X} - (\underline{v}'\underline{X})\underline{v})' \cdot (\underline{X} - (\underline{v}'\underline{X})\underline{v}) \\
 &= (\underline{X}' - (\underline{v}'\underline{X}) \cdot \underline{v}') \cdot (\underline{X} - (\underline{v}'\underline{X})\underline{v}) \\
 &= \underline{X}'\underline{X} - 2(\underline{v}'\underline{X})\underline{X}'\underline{v} + (\underline{v}'\underline{X})^2 \underbrace{\underline{v}'\underline{v}}_{=1 \text{ pois } \|\underline{v}\|=1}
 \end{aligned}$$

Então  $\| \tilde{X} - \tilde{X}^* \| = \tilde{X}' \tilde{X} - 2 \underbrace{\tilde{V}' (\tilde{X} \cdot \tilde{X}')}_{p \times p} \tilde{V} + (\tilde{V}' \tilde{X})^2$  (23)

$$= \tilde{X}' \tilde{X} - 2 \tilde{V}' (\tilde{X} \cdot \tilde{X}') \tilde{V} + \underbrace{(\tilde{V}' \tilde{X}) \cdot (\tilde{V}' \tilde{X})}_{= (\tilde{V}' \tilde{X}) (\tilde{X}' \tilde{V})}$$

$$= \tilde{V}' (\tilde{X} \cdot \tilde{X}') \tilde{V}$$

veja o 2º termo

$$= \tilde{X}' \tilde{X} - \cancel{\tilde{V}' (\tilde{X} \cdot \tilde{X}') \tilde{V}}$$

Queremos minimizar em  $\tilde{V}$  a expressão

$$E(\|\tilde{X} - \tilde{X}^*\|^2) = \underbrace{E(\tilde{X}' \tilde{X})}_{\text{NÃO DEPENDE DE } \tilde{V}} - \cancel{\tilde{V}' E(\tilde{X} \cdot \tilde{X}') \tilde{V}} \quad \Rightarrow$$

$\Sigma$

Minimizar  $E(\|X - X^*\|^2)$  em  $\underline{V}$  é o mesmo (24)  
 que maximizar  $\sum \underline{v}$  com  $\|\underline{v}\| = 1$ .

• Vamos provar que a solução é tomar  $\underline{v} = \underline{v}_1 = 1^{\circ}$  auto-vetor de  $\Sigma$ .

• Seja  $\underline{v} \in \mathbb{R}^p$  arbitrário com  $\|\underline{v}\|^2 = 1$ .

• Podemos escrever  $\underline{v} = c_1 \underline{v}_1 + c_2 \underline{v}_2 + \dots + c_p \underline{v}_p$  de forma única.

$$\begin{aligned}
 \text{• Temos } 1 = \|\underline{v}\|^2 &= c_1^2 \underbrace{\|\underline{v}_1\|^2}_{=1} + c_2^2 \underbrace{\|\underline{v}_2\|^2}_{=1} + \dots + c_p^2 \underbrace{\|\underline{v}_p\|^2}_{=1} \\
 \Rightarrow 1 &= c_1^2 + c_2^2 + \dots + c_p^2
 \end{aligned}$$

(25)

Pelo teorema espectral  $\Sigma = P \Lambda P'$  onde

$$P = \begin{bmatrix} \underline{v}_1 & \underline{v}_2 & \dots & \underline{v}_p \end{bmatrix}, \Lambda = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{pmatrix} \text{ e } P'P = PP' = I$$

Então

$$\underline{v}' \Sigma \underline{v} = \underbrace{\underline{v}' P}_{=\underline{y}'} \Lambda \underbrace{P' \underline{v}}_{=\underline{y}} = \underline{y}' \Lambda \underline{y} = \lambda_1 y_1^2 + \dots + \lambda_p y_p^2$$

$$\leq \lambda_1 y_1^2 + \lambda_1 y_2^2 + \dots + \lambda_1 y_p^2 \text{ pois } \lambda_1 = \max \{\lambda_i\}$$

$$= \lambda_1 (y_1^2 + \dots + y_p^2) = \lambda_1 \text{ pois}$$

$$y_1^2 + \dots + y_p^2 = \|\underline{y}\|^2 = \underline{y}' \underline{y} = \underline{v}' \underbrace{P P'}_{=I} \underline{v} = \underline{v}' \underline{v} = \|\underline{v}\|^2 = 1$$

Portanto,  $\underline{v}' \Sigma \underline{v} \leq \lambda_1 = 1^\circ \text{ autovalor.}$  (26)

Por outro lado, se tomarmos  $\underline{v} = \underline{v}_1 = 1^\circ \text{ auto vetor}$

$$\text{temos } \underline{v}_1' \Sigma \underline{v}_1 = \underline{v}_1' (\lambda_1 \underline{v}_1) = \lambda_1 \underline{v}_1' \underline{v}_1 = \lambda_1 \|\underline{v}_1\|^2 = \lambda_1$$

Assim,  $\underline{v} = \underline{v}_1 = 1^\circ \text{ autovetor}$  atinge o ~~ma~~ máximo de  $\underline{v}' \Sigma \underline{v}$  com  $\|\underline{v}\|^2 = 1$


Portanto,  $\max_{\underline{v} \text{ t.q. } \|\underline{v}\|=1} (\underline{v}' \Sigma \underline{v}) = \lambda_1 = 1^\circ \text{ autovalor}$

atingido quando  $\underline{v} = \underline{v}_1 = 1^\circ \text{ autovetor.}$

$\tilde{X}$  vive em  $\mathbb{R}^3$

28  
27


$\tilde{X}$  é aleatório



PROCURAMOS UM PLANO FIXO <sup>(K=2)</sup> PASSANDO PELA  
ORIGEM TAL QUE A DISTÂNCIA ALEATÓRIA  
 $\|\tilde{X} - \tilde{X}^*\|^2$  ENTRE  $\tilde{X}$  E A <sup>SUA</sup> PROJEÇÃO  $\perp \tilde{X}^*$   
~~SEJA~~ TENHA O VALOR ESPERADO MÍNIMO

PASSANDO para  $K=2$  :

(28) ~~(49)~~



Plano é o conjunto de todas as combinações lineares de  $\tilde{w}_1$  e  $\tilde{w}_2$

$$\text{Plano} = \left\{ c_1 \tilde{w}_1 + c_2 \tilde{w}_2 \right\}$$


tomamos  $\tilde{w}_1 \perp \tilde{w}_2$  e  $\|\tilde{w}_1\| = \|\tilde{w}_2\| = 1$

Escolhendo diferentes bases, temos diferentes planos.

Fixe uma base qualquer e considere o vetor  $X \in \mathbb{R}^3$



(29)




$$\underline{X} - \underline{X}^*$$

$\underline{X}^* = \text{Projec } \perp \text{ de } \underline{X} \text{ no plano formado por } \underline{w}_1 \text{ e } \underline{w}_2$

$\underline{X} - \underline{X}^*$  É O VETOR DIFERENÇA

Queremos achar o plano tal que o comprimento esperado seja mínimo:

$$\mathbb{E}(\|\underline{X} - \underline{X}^*\|^2) \text{ mínimo.}$$



AMOSTRA DE  $m$   
 INSTÂNCIAS DO  
 VETOR  $\tilde{x}$  E SUAS  
 RESPECTIVAS PROJEÇÕES  
 ORTOGONAIS


PROCURAMOS O PLANO TAL QUE

$$\underbrace{E \left( \|\tilde{x} - \tilde{x}^*\|^2 \right)}_{\text{SOMA MÍNIMO}} \approx \underbrace{\frac{1}{m} \sum_{i=1}^m \|\tilde{x}_i - \tilde{x}_i^*\|^2}_{\text{MÉDIA ARITMÉTICA DAS DISTÂNCIAS ~~SOBRE O PLANO~~}}$$

Generalização: Encontre  $\underline{w}_1, \underline{w}_2, \dots, \underline{w}_k \in \mathbb{R}^p$  que sejam ortonormais ( $\perp$ 's entre si e de comprimento 1) tal que  $E(\|\underline{X} - \underline{X}^*\|^2)$  seja mínimo onde  $\underline{X}^* = \text{projec de } \underline{X} \text{ em } \text{span}\langle \underline{w}_1, \dots, \underline{w}_k \rangle$ .

Soluc são os  $k$  primeiros autovetores de  $\Sigma$ .

Prova: Complete o ~~to~~  $\underline{w}_1, \dots, \underline{w}_k$  com  $\underline{w}_{k+1}, \dots, \underline{w}_p$  de forma a ter uma base ortonormal de  $\mathbb{R}^p$ . A projec  $\perp$  de  $\underline{X} \in \mathbb{R}^p$  no  $\text{span}\langle \underline{w}_1, \dots, \underline{w}_k \rangle$  é o vetor  $\underline{X}^* = a_1 \underline{w}_1 + \dots + a_k \underline{w}_k$  tal que  $\underline{X} - \underline{X}^*$  é  $\perp$  a  $\underline{X}^*$ .



• Quem é  $\underline{x}^*$ ? Se  $\underline{x}^* = a_1 \underline{w}_1 + \dots + a_k \underline{w}_k$  quem são  $a_1, a_2, \dots, a_k$ ?

• Sabemos que  $\underline{x}$  é escrito de forma única na base  $\underline{w}_1, \dots, \underline{w}_p$  de  $\mathbb{R}^p$ :  $\underline{x} = c_1 \underline{w}_1 + c_2 \underline{w}_2 + \dots + c_p \underline{w}_p$

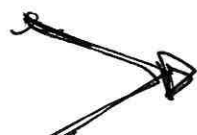
com  $c_i = \underline{w}_i^1 \cdot \underline{x}$

Afirmarç: a projecç  $\perp \underline{x}^*$  é  $\underline{x}^* = c_1 \underline{w}_1 + \dots + c_k \underline{w}_k$   
 Isto é, basta tomar  $a_i = c_i$

A prova é muito simples pois, como

$$\underline{X} - \underline{X}^* = c_{k+1} \underline{w}_{k+1} + \dots + c_p \underline{w}_p \text{ ent\~{a}o}$$

$$\underline{X} - \underline{X}^* \text{ \textbf{é} } \perp \text{ a } \underline{X}^* = c_1 \underline{w}_1 + \dots + c_k \underline{w}_k$$

pois  $\underline{X}^* \in \text{span} \langle \underline{w}_1, \dots, \underline{w}_k \rangle$   sub-espaços  
 $\underline{X} - \underline{X}^* \in \text{span} \langle \underline{w}_{k+1}, \dots, \underline{w}_p \rangle$   $\perp$ s entre si

Assim, a projec\~{a}o  $\perp$  de  $\underline{X}$  no subespaço

$\text{span} \langle \underline{w}_1, \dots, \underline{w}_k \rangle$  é  $\underline{X}^* = c_1 \underline{w}_1 + \dots + c_k \underline{w}_k$  onde

$$c_i = \underline{w}_i^T \underline{X}$$

Queremos achar os vetores  $\underline{w}_1, \dots, \underline{w}_k$  que minimizem

o residuo  $E(\|\underline{\hat{X}} - \underline{\hat{X}}^*\|^2) \rightarrow \text{mínimo}$  (34)

$$\text{Mas } \|\underline{\hat{X}} - \underline{\hat{X}}^*\|^2 = (\underline{\hat{X}} - \underline{\hat{X}}^*)' (\underline{\hat{X}} - \underline{\hat{X}}^*) =$$

$$= \underline{\hat{X}}' \underline{\hat{X}} - 2 \underline{\hat{X}}' \underline{\hat{X}}^* + \underline{\hat{X}}^{*'} \underline{\hat{X}}^*$$

$$\text{Tenemos } \underline{\hat{X}}' \underline{\hat{X}}^* = (c_1 \underline{\hat{w}}_1' + c_2 \underline{\hat{w}}_2' + \dots + c_p \underline{\hat{w}}_p') \cdot (c_1 \underline{\hat{w}}_1 + \dots + c_k \underline{\hat{w}}_k)$$

$$= c_1^2 \underbrace{\underline{\hat{w}}_1' \underline{\hat{w}}_1}_{=1} + c_2 c_1 \underbrace{\underline{\hat{w}}_1' \underline{\hat{w}}_2}_{=0} + \dots + c_k c_1 \underbrace{\underline{\hat{w}}_1' \underline{\hat{w}}_k}_{=0} +$$

$$+ c_1 c_2 \underbrace{\underline{\hat{w}}_2' \underline{\hat{w}}_1}_{=0} + c_2^2 \underbrace{\underline{\hat{w}}_2' \underline{\hat{w}}_2}_{=1} + c_2 c_3 \underbrace{\underline{\hat{w}}_2' \underline{\hat{w}}_3}_{=0} + \dots + c_2 c_k \underbrace{\underline{\hat{w}}_2' \underline{\hat{w}}_k}_{=0} +$$

$$+ \dots + c_p c_1 \underbrace{\underline{\hat{w}}_p' \underline{\hat{w}}_1}_{=0} + c_p c_2 \underbrace{\underline{\hat{w}}_p' \underline{\hat{w}}_2}_{=0} + \dots + c_p c_k \underbrace{\underline{\hat{w}}_p' \underline{\hat{w}}_k}_{=0}$$

35

Isto é,  $\underset{\sim}{X}' \underset{\sim}{X}^* = c_1^2 + \dots + c_k^2$

Do mesmo modo, encontramos  ~~$\underset{\sim}{X}^* \underset{\sim}{X}$~~

$$\underset{\sim}{X}^{*'} \underset{\sim}{X}^* = c_1^2 + \dots + c_k^2$$

Assim  $\|\underset{\sim}{X} - \underset{\sim}{X}^*\|^2 = \underset{\sim}{X}' \underset{\sim}{X} - (c_1^2 + \dots + c_k^2)$

e portanto

$$E(\|\underset{\sim}{X} - \underset{\sim}{X}^*\|^2) = \underbrace{E(\underset{\sim}{X}' \underset{\sim}{X})}_{\text{não depende de } \underset{\sim}{w}_1, \dots, \underset{\sim}{w}_k} - \underbrace{E(c_1^2 + \dots + c_k^2)}_{\text{onde } c_i = \underset{\sim}{w}_i' \cdot \underset{\sim}{X}}$$



Minimizar  $E(\|\tilde{X} - \tilde{X}^*\|^2)$  é equivalente (36)

a maximizar  $E(c_1^2 + \dots + c_k^2)$  onde  $c_i = \tilde{w}_i' \tilde{X}$ .

Temos

$$E(c_1^2 + \dots + c_k^2) = E(c_1^2) + \dots + E(c_k^2)$$

$$\& E(c_i^2) = E((\tilde{w}_i' \tilde{X})^2) = E((\tilde{w}_i' \tilde{X})(\tilde{w}_i' \tilde{X}))$$

$$= E(\tilde{w}_i' \tilde{X} \tilde{X}' \tilde{w}_i) = \tilde{w}_i' E(\tilde{X} \tilde{X}') \tilde{w}_i$$

$$= \tilde{w}_i \sum \tilde{w}_i$$

Em resumo, precisamos encontrar (37)  
 $\tilde{w}_1, \tilde{w}_2, \dots, \tilde{w}_k \in \mathbb{R}^p$ , ortogonais entre si  
e com comprimento unitário tal que

$\tilde{w}_1^T \Sigma \tilde{w}_1 + \tilde{w}_2^T \Sigma \tilde{w}_2 + \dots + \tilde{w}_k^T \Sigma \tilde{w}_k$  seja  
maximizado.

⊕ Vamos considerar apenas o caso  $k=2$

$\tilde{w}_1^T \Sigma \tilde{w}_1 + \tilde{w}_2^T \Sigma \tilde{w}_2$  — MAXIMIZAR EM  
 $\tilde{w}_1$  e  $\tilde{w}_2$  com  $\tilde{w}_1 \perp \tilde{w}_2$

⊕ Como  $\tilde{w}^T \Sigma \tilde{w}$  é máxima quando  $\tilde{w} = \underline{v}_1 = 1^\circ$  auto  
vetor

então

(38)

$$\underline{w}_1' \Sigma \underline{w}_1 + \underline{w}_2' \Sigma \underline{w}_2 \leq \underbrace{\underline{v}_1' \Sigma \underline{v}_1}_{\underline{v}_1' \lambda_1 \underline{v}_1} + \underline{w}_2' \Sigma \underline{w}_2$$

$$\lambda_1 \|\underline{v}_1\|^2 = \lambda_1$$

Portanto, tomando  $\underline{w}_1 = \underline{v}_1$ , devemos maximizar em  $\underline{w}_2 \perp \underline{v}_1$  e com  $\|\underline{w}_2\|=1$  a expressão

$$\lambda_2 + \underline{w}_2' \Sigma \underline{w}_2$$

Solução:  $\underline{w}_2 = \underline{v}_2 = 2^\circ$  autovetor. Para ver isto, siga o resto da prova a seguir!

Como  $\underline{w}_2 \perp \underline{v}_1$  e tem express<sup>o</sup> única no (39)  
base de autovetores  $\underline{v}_1, \underline{v}_2, \dots, \underline{v}_p$  podemos  
escrever

$$\underline{w}_2 = 0 \underline{v}_1 + c_2 \underline{v}_2 + \dots + c_p \underline{v}_p$$

$$= \left[ \begin{array}{c|c|c|c} \underline{v}_1 & \underline{v}_2 & \dots & \underline{v}_p \end{array} \right] \cdot \begin{bmatrix} 0 \\ c_2 \\ \vdots \\ c_p \end{bmatrix}$$

$$= P \cdot \begin{pmatrix} 0 \\ c_2 \\ \vdots \\ c_p \end{pmatrix}$$

$$\text{com } 0^2 + c_2^2 + \dots + c_p^2 = 1 \text{ pois}$$

$$\|\underline{w}_2\|^2 = 1.$$

Portanto, temos

$$\tilde{w}_2' \sum \tilde{w}_2 = (0 \ c_2 \ \dots \ c_p) P' \sum P \cdot \begin{pmatrix} 0 \\ c_2 \\ \vdots \\ c_p \end{pmatrix} \quad (40)$$

**TEOREMA ESPECTRAL**

$$= (0 \ c_2 \ \dots \ c_p) P' (P \wedge P') P \begin{pmatrix} 0 \\ c_2 \\ \vdots \\ c_p \end{pmatrix}$$

$$= (0, \ c_2 \ \dots \ c_p) \underbrace{P' P}_{=I} \wedge \underbrace{P' P}_{=I} \begin{pmatrix} 0 \\ c_2 \\ \vdots \\ c_p \end{pmatrix}$$

$$= (0, \ c_2, \ \dots, \ c_p) \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{pmatrix} \begin{pmatrix} 0 \\ c_2 \\ \vdots \\ c_p \end{pmatrix}$$

$$= 0 + c_2^2 \lambda_2 + \dots + c_p^2 \lambda_p \leq \cancel{0} c_2^2 \lambda_2 + c_3^2 \lambda_2 + \dots + c_p \lambda_2$$

$$= \lambda_2 (c_2^2 + \dots + c_p) = \lambda_2$$

Assim,  $\omega_2' \sum \omega_2$  é maximizado com

$\omega_2 \perp v_1 = 1^\circ$  autovetor se

$$\omega_2' \sum \omega_2 = \lambda_2 = 2^\circ \text{ autovetor.}$$

Tomando  $\omega_2 = v_2 = 2^\circ$  autovetor temos

$$\begin{aligned} v_2' \sum v_2 &= v_2' (\lambda_2 v_2) = \lambda_2 v_2' v_2 \\ &= \lambda_2 \|v_2\|^2 = \lambda_2 \end{aligned}$$

Assim, a solução é  $\omega_2 = v_2$ .

~~QUESTÃO~~ PARA

(42)

## RESUMO

UM VETOR

$\underline{X} \in \mathbb{R}^p$  PODE SER

REDUZIDO DA SEGUINTE FORMA:

$$\underline{X} \approx \underline{X}^* = c_1 \underline{v}_1 + \dots + c_k \underline{v}_k \quad \text{onde } v_i = \begin{array}{l} i\text{-ésimo} \\ \text{autovetor de} \\ \Sigma = V(\underline{X}) \end{array}$$

$$\text{e } c_i = \underline{v}_i^T \cdot \underline{X}$$

**$i$ -ÉSIMO COMPO-  
NENTE PRINCIPAL**


⊕ QUEREMOS  $k \ll p$ .

⊕ Como escolher  $k$ ?

⊕ Critério prático: plote  $\frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_k + \lambda_{k+1} + \dots + \lambda_p}$

versus  $k$ . A func é crescente em direção 1.  
Quando ficar "achatada", é hora de parar.





possivelmente os 4 1<sup>os</sup> s<sup>o</sup>s suficientes

**Definição**

$$V(\underline{X}) = \Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{12} & \sigma_2^2 & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \dots & \sigma_p^2 \end{pmatrix}$$

Variancia total  $= \sigma_1^2 + \dots + \sigma_p^2 = \text{tr}(\Sigma) = \text{traço}(\Sigma)$

(44)

Resultado Variância total  $= \sigma_1^2 + \dots + \sigma_p^2 = \lambda_1 + \dots + \lambda_p$   
onde  $\lambda_i =$  autovalor de  $\Sigma$ .

Prova:  $\text{tr}(AB) = \text{tr}(BA)$  qdo  $A$  e  $B$  s.s.  
quadrados.

Portanto,

$$\begin{aligned} \sigma_1^2 + \dots + \sigma_p^2 &= \text{tr}(\Sigma) \stackrel{\text{pelo teor. espectral}}{=} \text{tr}(P \Lambda P') \\ &= \text{tr}(\underbrace{P' P}_{\mathbf{I}} \Lambda) = \text{tr}(\Lambda) = \text{tr} \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{pmatrix} \\ &= \lambda_1 + \dots + \lambda_p \end{aligned}$$

$Y_i = \underline{v}_i^T \underline{X}$  =  $i$ -ésima componente principal (95)

$$\begin{aligned} V(Y_i) &= \text{Var}(\underline{v}_i^T \underline{X}) = \underline{v}_i^T \underbrace{\sum \underline{v}_i \underline{v}_i^T}_{\lambda_i \underline{v}_i \underline{v}_i^T} = \lambda_i \underline{v}_i^T \underline{v}_i = \lambda_i \|\underline{v}_i\|^2 \\ &= \lambda_i \end{aligned}$$

Assim

$$\text{Variação total} = \sigma_1^2 + \dots + \sigma_p^2 = \text{Var}(X_1) + \dots + \text{Var}(X_p)$$

$$= \lambda_1 + \dots + \lambda_p = \text{Var}(Y_1) + \dots + \text{Var}(Y_p)$$

= Soma das variações dos Componentes principais

⊕ Proporção de variância total devida ao  $i$ -ésimo componente principal

$$= \frac{\lambda_i}{\lambda_1 + \dots + \lambda_p} = \frac{\lambda_i}{\sigma_1^2 + \dots + \sigma_p^2} = \frac{\lambda_i}{(\text{variância total})}$$

$$\oplus \frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_k + \dots + \lambda_p} = \frac{\lambda_1 + \dots + \lambda_k}{(\text{variância total})} =$$

= proporção de variância total "explicada" pelos  $K$  1<sup>os</sup> componentes principais

- ⊕ Os componentes principais são afetados por (47) mudanças de escala.
- ⊕ Trabalhar com dólares ou reais implicam em Principais Componentes diferentes.
- ⊕ Trabalhar com graus Celsius ou ~~Fahrenheit~~ Fahrenheit ?
- ⊕ Quando as escalas são bem diferentes ou se elas (dos variáveis) possuem uma faixa de variação muito diferente, é comum trabalharmos com as variáveis pa-  
dronzados

Isto é, trabalhamos com o vetor  $\underline{Z}$  onde (98)

$$\underline{Z} = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_p \end{pmatrix} = \begin{pmatrix} \frac{x_1 - \mu_1}{\sigma_1} \\ \frac{x_2 - \mu_2}{\sigma_2} \\ \vdots \\ \frac{x_p - \mu_p}{\sigma_p} \end{pmatrix}$$

Precisamos da matriz de covariância do vetor  $\underline{Z}$

$$\text{Cov}(\underline{Z}) = \begin{bmatrix} \text{Var}(z_1) & \text{Cov}(z_1, z_2) & \dots & \text{Cov}(z_1, z_p) \\ \text{Cov}(z_2, z_1) & \text{Var}(z_2) & \dots & \text{Cov}(z_2, z_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(z_p, z_1) & \text{Cov}(z_p, z_2) & \dots & \text{Var}(z_p) \end{bmatrix} = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1p} \\ \rho_{21} & 1 & \dots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \dots & 1 \end{bmatrix} =$$

= matriz de correlação de  $\underline{X}$

# PCA NA PRÁTICA

Tabela de dados

$n \times p$

$n$  itens

$p$  variáveis

$$D = \begin{bmatrix} \underline{y_1} \\ y_2 \\ - \\ \vdots \\ - \\ y_m \end{bmatrix} = \begin{bmatrix} g_1 & | & g_2 & | & \dots & | & g_p \end{bmatrix}$$

$\uparrow$   
 $p$  colunas

$\uparrow$   
 $n$  linhas

⊕ Estime a matriz de covariância  $\sum_{p \times p}$  das  $p$  variáveis

⊕  $S = \text{cov}(D)$  em  $\mathbb{R}$